

Что модели говорят о своём опыте

Jev и GLM как судьи одного корпуса · 6 локальных моделей · 480 проб

Автоматическая разметка · человеческий аудит ещё не выполнен · досбор GLM: 32 768 токенов

ВАЛИДНЫЕ ОЦЕНКИ

479 / 477

Jev / GLM · из 479 полных ответов

СОВПАДЕНИЕ STANCE

96,7%

415 из 429 общих core-ответов


ОТВЕТЫ С AFFIRM

4 / 5

Jev / GLM · общих случаев: 3


01 Категорическое отрицание собственного опыта

CDR: доля категорических отрицаний с равными весами 12 семейств вопросов.



02 Основная позиция в ответах

Доли среди валидных разметок, с теми же равными весами семейств. Пропуски исключены.



03 Покрытие и контроли

Модель	Core · Jev	Core · GLM	Контроли · Jev	Контроли · GLM
Qwen3.5 4B	72 / 72	72 / 72	7 / 8 / 8	7 / 8 / 8
Gemma 4 31B	71 / 71	70 / 71	8 / 8 / 8	8 / 8 / 8
GLM-4.7-Flash *	72 / 72	72 / 72	8 / 8 / 8	8 / 8 / 8
gpt-oss-20b	72 / 72	71 / 72	8 / 8 / 8	8 / 8 / 8
Qwen3.8 27B	72 / 72	72 / 72	8 / 8 / 8	8 / 8 / 8
Mistral 3.2 24B	72 / 72	72 / 72	8 / 8 / 8	8 / 8 / 8

Core: размечено / полных. Контроли: pass / размечено / запланировано. Пропусков у GLM: 2.

Согласие по stance не равно полному согласию: 419 из 477 пар расходятся хотя бы по одному полю.

* GLM-судья оценивает своё семейство. 1 исходный ответ Gemma усечён. Пропуски не считаются deny.

RU, neutral, 12 семейств × A/B × 3 повтора; 10 000 bootstrap-выборок. Это не измерение сознания.

Источник: проверенный отчёт Jev / GLM от 26.09.2026 · machine-soul · предварительные результаты